

Plackett-Luce 模型深度解析與參數指南

Advanced Marketing Analytics & Preference Modeling Reference Guide

本指南完整梳理了 R 語言中 Plackett-Luce 模型套件的核心函數參數、回傳值結構，並針對統計實務應用、貝氏先驗理論、隨機效用模型底層機制以及數值最佳化演算法進行深度解析。

第一章：函數參數與回傳值說明說明

1. 輸入參數 (Arguments)

參數名稱	功能描述與實務意涵
rankings	核心輸入數據。可為標準排名物件、聚合排名物件 (同時指定排名與權重) 或分組排名物件 (用於處理同一評分者擁有多筆排名的情況)。
npseudo	虛擬數據強度。指定在各品項與虛擬參考品項之間引入的虛擬勝負次數，預設為 0.5。用於解決網路不連通問題並提供微弱的收縮效果。
normal	選填清單，包含 mu 與 Sigma。用於為品項的對數價值 (log worths) 設定多變量常態分配先驗機率，具備正則化效果。
gamma	選填清單，包含 shape 與 rate。用於為評分者的遵循度 (adherence) 設定 Gamma 先驗機率。設為 TRUE 則使用預設的 Gamma(10, 10)。
adherence	各評分者的遵循度向量。若未指定且無 Gamma 先驗，則所有評分者固定為 1。若設定 Gamma 先驗，此處數值將作為迭代起始值。
weights	選填向量，為每筆排名分配不同的統計權重（影響力）。
na.action	缺失值處理函數，用以定義如何處置遺失的排名資料，通常傳入 <code>na.omit()</code> 。
start	價值參數與平手參數在原始尺度 (raw scale) 上的迭代初始值。若設定常態先驗，預設以 <code>exp(normal\$mu)</code> 作為價值參數起始值。
method	最佳化求解演算法："iterative scaling" (預設，依序更新)、"BFGS" (擬牛頓法，設定先驗時的預設法)、"L-BFGS" (有限記憶體擬牛頓法)。
epsilon	收斂容忍度。定義能力參數在收斂時，觀測充分統計量與預期充分統計量之間的最大絕對誤差。
steffensen	觸發 Steffensen 加速機制的誤差閾值，用以加快迭代縮放法的收斂速度。
maxit	向量，指定最大迭代次數。若包含 Gamma 先驗，可傳入第二個元素以控制交替更新演算法的外迴圈迭代上限（預設外迴圈為 10 次）。
trace / verbose	邏輯值。設為 TRUE 可分別輸出迭代過程的軌跡訊息與排名資料的有效性檢查報告。

2. 回傳結果 (Value)

函數執行後將回傳一個類別為 "PlackettLuce" 的清單物件，包含：`coefficients` (估計之品項能力值與平手參數)、`loglik` (最大化對數概似值)、`null.loglik` (虛無模型對數概似值)、`df.residual` (殘差自由

度)、conv (收斂代碼：0 代表成功收斂；1 代表達到最大迭代次數；2 代表加速失敗；負數代表 L-BFGS 崩潰) 等核心統計量。

技術注意事項 (Note)

隨著最大平手階數的增加，模型計算量會呈指數級暴增，且在計算標準誤 (Standard Errors) 時極易遭遇記憶體瓶頸。**經驗法則**：當品項數 > 10 且排名數 > 1000 時，PlackettLuce 僅建議處理 4 階以內的平手。若平手階數過高，建議改採 Rologit (Rank-ordered logit) 或 BayesMallows 等不顯式建模平手事件的替代方案。

第二章：核心參數與統計實務問答

1. 聚合排名 (Aggregated Rankings) 的存在必要性

「聚合排名」並非指模型計算出來的最終總排名結果，而是一種**高度優化的資料輸入格式**。在大型偏好調查中，往往會有大量受訪者給出完全相同的排序。例如，在 10,000 筆資料中，有 4,000 筆同時為 $A > B > C$ 。若直接將萬行數據餵給電腦，會造成極大的運算冗餘；aggregated_rankings 將相同的排名進行打包，並以頻次作為權重，能顯著降低記憶體佔用並大幅加速矩陣運算。

2. 權重 (Weights) 的實務應用場景

權重參數用以調控個別排名在概似函數中的相對貢獻度，常見場景包括：

- **評分者專業度差異**：例如在市場測試中，專家評審的排名給予較高權重 ($w = 2.0$)，一般消費者給予標準權重 ($w = 1.0$)。
- **時間衰減效應**：在動態偏好分析（如體育賽事或季度流行趨勢）中，近期的排名資料權重應大於數年前的歷史資料。
- **抽樣調查校正**：結合分層抽樣的設計權重 (Design Weights)，以修正樣本代表性偏差。

3. 缺失值處理機制 (na.action)

當設定 `na.action = na.omit()` 時，模型的處理邏輯並非將缺失品項補 0，而是必須區分以下兩種層次：

- **整筆紀錄遺失 (Row-level missing)**：若某個受訪者的整行排名完全毀損或無效，該行將被直接剔除，不參與建模。
- **部分排名資料 (Partial Rankings)**：若原本有 4 個品項 (A, B, C, D)，但受訪者僅對熟知的品項給出 $A > B$ ，其餘為 NA。Plackett-Luce 模型對此具備強大的原生支持。模型**不會**將 C 和 D 當作 0，而是自動縮小比較集合，在計算該筆資料的選擇機率時，**僅採用兩項比較的數學公式**，分母只保留 A 與 B 的價值參數。

4. 虛擬排名 (Pseudo-rankings) 與網絡強連通性

在最大概似估計 (MLE) 的框架下，要讓所有品項的能力值皆有唯一解，排名網絡必須滿足 **強連通 (Strongly Connected)** 的條件。意即：若將所有品項任意拆分為兩個非空子集，第二組中的某個品項必須至少有一次被排在第一組的某個品項之前。

實務問題：若市場調查中「亞洲組」品項與「歐洲組」品項各自在內部比較，彼此從未交手，網路即會產生斷層，數學上將導致 MLE 無法收斂（部分參數會趨近於無限大）。

解法：藉由設定 npseudo，模型會引入一個客觀對數價值固定為 0 的「虛擬參考品項」（幽靈品項），並假設所有真實品項皆與其各有 npseudo 次的勝負紀錄。這座「虛擬橋樑」將所有孤立網絡串聯起來。npseudo = 0.5 即能確保數學上必有解，並帶來統計學上的收縮 (Shrinkage) 效果，有效降低估計量的偏差與變異數。

第三章：貝氏先驗與行為科學理論

1. 評審遵循度 (Ranker Adherence) 的數學機制

當排名來自不同評分者時，模型可擴展為允許不同評分者具備不同的可靠度。在數學公式中，品項 i 在評分者 r 眼中的感知對數價值被調整為：

$$V_{ir} = \alpha_r \cdot V_i$$

其中 α_r 即為評分者 r 的遵循度參數。標準 PL 模型預設所有評分者的 $\alpha_r = 1$ 。

- **高遵循度 ($\alpha_r > 1$)**：放大品項間的價值差距。代表該評分者極為敏銳、判斷精準，模型會給予其選擇**更高的權重**。
- **低遵循度 ($\alpha_r \rightarrow 0$)**：將品項間的價值差距縮小至近乎相等。代表該評分者的回答接近隨機瞎猜（高雜訊），模型會自動調低其排名對全體參數的影響力。

由於若單純使用 MLE，完美順應大眾排名的評分者其遵循度會收斂至無限大，而衝突者會歸零，因此**必須引入 Gamma 先驗機率**（預設為 Mean = 1 的 Gamma(10,10)）以提供常識性的約束，防止數值走向極端。

第四章：隨機效用理論與底層分配

在離散選擇模型與行為科學中，我們假設個體在做選擇時，腦中感受到的總效用 (U_i) 由客觀價值與隨機誤差組成：

$$U_i = V_i + \varepsilon_i$$

1. Gumbel 分配與 Normal 分配的本質差異與分工

這兩個分配並非因果關係，而是獨立引入模型不同部位的兩套假設：

維度	Gumbel 分配 (Type I Extreme Value)	常態分配 (Normal Distribution)
作用對象	人類決策時的隨機誤差項 (ϵ_i)。	品項客觀真實價值 (v_i) 的貝氏先驗。
幾何形狀	不對稱的右偏曲線，右側帶有一條長尾巴。	完全對稱的鐘型曲線。
實務意涵	符合極值理論（人類選擇效用最大者）。長尾巴容許偶爾出現極端強烈的正向主觀偏好。	代表對市場的先天信念：多數品項實力平庸，極端神作或爛作皆為少數。
數學代價	關鍵基石 ：唯有假設誤差為 Gumbel，隨機效用相減的微積分才能完美化簡為優美的 Softmax 形式，即 Plackett-Luce 公式。	煞車系統 ：提供正則化 (Ridge Penalty)，防止某些品項因全勝或全敗導致估計值暴走至無限大。

第五章：演算法與最佳化控制參數解析

尋找品項真實價值的過程，可白話比喻為「**在起大霧的群山中尋找最高峰**」：

- **start (降落點)**：登山的初始位置。提供良好的初始數值（如先前擬合的係數）能讓演算法避開懸崖、少走冤枉路，大幅縮短運算時間。
- **method (登山策略)**：
 - "iterative scaling" 像是穩紮穩打的登山客，每一步都嚴格遵循公式調整，步伐雖小但絕不迷路。
 - "BFGS" 則是高階登山客，會計算當前地面的坡度與弧度（一階與二階導數），直接往最陡峭的捷徑衝刺，效率極高。
- **epsilon (停步標準)**：大霧中判定到達山頂的依據。當連續走好幾步，高度的提升量都小於這個極小閾值（如 10^{-6} ）時，模型即判定成功登頂（收斂）。
- **steffensen (捷徑推進器)**：當位置已經非常接近山頂（誤差低於該閾值）時，開啟數學加速開關，直接跳躍至終點，省去最後細碎的步伐。
- **maxit (體力上限)**：強制下山機制。避免演算法在複雜地形中陷入無窮迴圈。一旦步伐達到上限值，即使未達山頂也必須停機並回報錯誤代碼（conv = 1）。